ĐỀ CƯƠNG NGHIÊN CỨU KHOA HỌC VÀ CÔNG NGHỆ SINH VIÊN 2026

Tên đề tài: Nghiên cứu xây dựng hệ thống trích xuất và cấu trúc hóa thông tin tự động từ văn bản hành chính tiếng Việt sử dụng Mô hình ngôn ngữ lớn (LLMs) và công nghệ OCR phục vụ công tác chuyển đổi số.

1. TỔNG QUAN VÀ TÍNH CẤP THIẾT CỦA ĐỀ TÀI

1.1. Bối cảnh thực tiễn

Trong xu thế Chuyển đổi số quốc gia và thực hiện Đề án 06 của Chính phủ, khối lượng văn bản hành chính (Công văn, Quyết định, Tờ trình...) tại các cơ quan nhà nước đang gia tăng theo cấp số nhân. Tuy nhiên, quy trình xử lý hiện tại vẫn tồn tại điểm nghẽn lớn:

- **Chuyển đổi số chưa triệt để:** Đa phần mới chỉ dừng lại ở mức "số hóa tài liệu" (Digitization) – tức quét văn bản giấy thành file ảnh/PDF.
- **Dữ liệu "chết":** Nội dung bên trong các file scan này là dữ liệu phi cấu trúc (unstructured data), máy tính không thể hiểu, tra cứu hay phân tích. Việc khai thác dữ liệu hoàn toàn phụ thuộc vào quy trình nhập liệu thủ công, tốn kém thời gian và dễ sai sót.

1.2. Khoảng trống công nghệ ("Tam giác thách thức")

Các giải pháp OCR truyền thống hiện có trên thị trường gặp thất bại khi xử lý văn bản hành chính Việt Nam do 03 thách thức đặc thù:

1. **Nhiễu chồng lấn (Overlapping Noise):** Con dấu đỏ thường đóng đè lên chữ ký, ngày tháng và tên người ký, làm tê liệt các thuật toán nhận dạng quang học thông thường.
2. **Đa dạng hình thái:** Sự kết hợp phức tạp giữa font chữ in (Serif/Sans-serif) và chữ ký viết tay tự do.
3. **Thiếu ngữ nghĩa:** OCR truyền thống chỉ trả về văn bản thô. Máy tính không phân biệt được vai trò của thông tin (ví dụ: đâu là "Ngày ban hành", đâu là "Ngày hiệu lực") để tự động điền vào cơ sở dữ liệu.

=> Giải pháp: Cần một hệ thống tích hợp giữa **Thị giác máy tính (Computer Vision)** để xử lý nhiễu ảnh và **Trí tuệ nhân tạo tạo sinh (GenAI/LLM)** để hiểu ngữ nghĩa, hoạt động hoàn toàn cục bộ (On-premise) để đảm bảo an toàn dữ liệu.

2. MỤC TIÊU NGHIÊN CỨU

Đề tài hướng tới 03 mục tiêu cốt lõi:

- **Mục tiêu 1 (Thị giác máy - The Eye):** Xây dựng module tiền xử lý ảnh và OCR chuyên dụng cho tiếng Việt, có khả năng loại bỏ nhiễu con dấu đỏ và nhận dạng chính xác văn bản trong điều kiện nhiễu.
- **Mục tiêu 2 (Ngôn ngữ - The Brain):** Tinh chỉnh (Fine-tune) mô hình ngôn ngữ lớn (LLM) mã nguồn

mở để thực hiện tác vụ trích xuất thông tin (Information Extraction) và chuẩn hóa dữ liệu đầu ra dưới dạng JSON.

- **Mục tiêu 3 (Hệ thống - The System):** Tối ưu hóa mô hình để triển khai hiệu quả trên thiết bị phần cứng phổ thông (Laptop/PC cấu hình cao), đảm bảo tính bảo mật (không gửi dữ liệu ra Internet).

3. NỘI DUNG VÀ PHƯƠNG PHÁP NGHIÊN CỨU (GIẢI PHÁP KỸ THUẬT)

Hệ thống được xây dựng theo kiến trúc đường ống (Pipeline) gồm 04 giai đoạn xử lý:

Giai đoạn 1: Tiền xử lý và Khử nhiễu ảnh (Image Preprocessing)

- **Thách thức:** Xử lý con dấu đỏ che khuất chữ.
- **Giải pháp:** Ứng dụng mạng nơ-ron đối kháng sinh (GANs), cụ thể là kiến trúc **Pix2Pix**.
  - Mô hình được huấn luyện trên tập dữ liệu giả lập (Synthetic Data) gồm các cặp ảnh: {Ảnh văn bản sạch} - {Ảnh văn bản có chèn dấu giả}.
  - Kết quả: Hệ thống học cách "bóc tách" lớp mực dấu đỏ, khôi phục lại các nét chữ đen bị che khuất bên dưới.

Giai đoạn 2: Nhận dạng ký tự quang học (OCR Engine)

- **Công nghệ:** Sử dụng mô hình **PaddleOCR** hoặc **VietOCR** (Transformer-based).
- **Tối ưu hóa:** Huấn luyện lại (Retrain) trên bộ dữ liệu văn bản hành chính tiếng Việt để tăng cường khả năng nhận diện các font chữ đặc thù (VnTime, Times New Roman) và các ký tự tiếng Việt có dấu bị mờ/nhòe.

Giai đoạn 3: Trích xuất thông tin bằng LLM (LLM Reasoning)

Đây là trái tim của hệ thống, giải quyết bài toán "Hiểu" văn bản.

- **Mô hình cơ sở (Base Model):** Lựa chọn **Qwen-2.5-7B-Instruct**.
  - *Lý do:* Đây là mô hình 7 tỷ tham số có hiệu năng xử lý tiếng Việt và tuân thủ định dạng lệnh (Instruction Following) tốt nhất hiện nay trong phân khúc tầm trung.
- **Kỹ thuật Tinh chỉnh (Optimization):** Áp dụng kỹ thuật **QLoRA (Quantized Low-Rank Adaptation)**.
  - Nén mô hình xuống định dạng **4-bit (Int4)**.
  - Kết quả: Mô hình chỉ chiếm dụng khoảng **5.5GB VRAM**, cho phép vận hành trơn tru trên các GPU có 8GB VRAM (như RTX 3060/4060/5070) mà vẫn giữ được độ chính xác gần tương đương bản gốc.
- **Nhiệm vụ:** Nhận đầu vào là văn bản thô từ OCR -> Phân tích ngữ nghĩa -> Trích xuất các trường: *Số hiệu, Trích yếu, Ngày tháng, Người ký* -> Trả về JSON.

Giai đoạn 4: Xây dựng Ứng dụng và Triển khai

- **Backend:** Python (FastAPI) tích hợp các module AI.
- **Frontend:** Giao diện Web (ReactJS) hỗ trợ chế độ xem song song (Side-by-side View) để người dùng

đối soát kết quả.
- **Cơ sở dữ liệu:** PostgreSQL/MongoDB lưu trữ kết quả.

4. TÍNH KHẢ THI CỦA ĐỀ TÀI (PHÂN TÍCH HẠ TẦNG)

Nghiên cứu đã được đánh giá tính khả thi kỹ thuật dựa trên hạ tầng thiết bị hiện có của nhóm nghiên cứu, chứng minh khả năng triển khai thực tế tại đơn vị cơ sở (On-premise Deployment).

4.1. Môi trường triển khai thử nghiệm (Testbed)

Hệ thống được phát triển và vận hành trên thiết bị Mobile Workstation với cấu hình:

- **CPU:** Intel Core i7-14700HX (High Performance).
- **RAM: 64GB** - *Yếu tố then chốt:* Đảm bảo khả năng chạy đa nhiệm (Load Model AI, Database, Web Server và Caching dữ liệu) mà không gặp nghẽn cổ chai bộ nhớ.
- **GPU:** NVIDIA **RTX 5070 (8GB VRAM)** - *Yếu tố then chốt:* Đủ dung lượng để chứa mô hình Qwen-7B (sau khi lượng tử hóa 4-bit ~5.5GB) và module OCR, đảm bảo tốc độ suy luận thời gian thực (Real-time Inference).
- **Lưu trữ:** SSD tốc độ cao (3TB) phục vụ lưu trữ Dataset và Database.

4.2. Đánh giá hiệu năng dự kiến

- **Tốc độ:** Xử lý trọn vẹn 01 trang văn bản trong < 5 giây (bao gồm cả OCR và LLM Extraction).
- **Độ chính xác:**
  - OCR (CER): < 5% trên văn bản chất lượng trung bình.
  - Trích xuất thông tin (F1-Score): > 90% đối với các trường thông tin tiêu chuẩn.

5. KẾ HOẠCH TRIỂN KHAI VÀ KẾT QUẢ DỰ KIẾN (Tiến độ 03 Tháng)

Do yêu cầu cấp thiết và sự hỗ trợ từ hạ tầng phần cứng hiệu năng cao (RTX 5070), đề tài được thực hiện theo quy trình nước rút (Sprint) trong 12 tuần:

5.1. Kế hoạch chi tiết

- **Tháng 1: Xây dựng Dữ liệu & Module OCR (The Eye)**
  - **Tuần 1-2:** Thu thập 500-1000 mẫu văn bản hành chính; Xây dựng tool tạo dữ liệu giả lập (Synthetic Data) để mô phỏng con dấu đỏ đè chữ.
  - **Tuần 3-4:** Huấn luyện mô hình Pix2Pix (Xóa dấu) và tinh chỉnh PaddleOCR. Đánh giá sơ bộ độ chính xác nhận dạng.
- **Tháng 2: Phát triển Module LLM & Backend (The Brain)**
  - **Tuần 5-6:** Thực hiện Fine-tuning mô hình Qwen-7B bằng kỹ thuật QLoRA trên dữ liệu đã gán nhãn.
  - **Tuần 7-8:** Đóng gói các mô hình AI thành API Service (FastAPI). Thiết kế cơ sở dữ liệu lưu trữ.
- **Tháng 3: Tích hợp Hệ thống & Đóng gói (Integration)**

- **Tuần 9-10:** Xây dựng giao diện Web App (ReactJS) kết nối với API; Tích hợp tính năng xem song song (Side-by-side).
- **Tuần 11-12:** Kiểm thử toàn hệ thống (End-to-end testing), sửa lỗi và viết báo cáo tổng kết đề tài.

5.2. Sản phẩm dự kiến

1. **Bộ dữ liệu chuẩn:** Dataset văn bản hành chính đã gán nhãn & Code tạo dữ liệu giả lập.
2. **Mô hình AI:** 01 Mô hình OCR xóa dấu và 01 Mô hình LLM chuyên dụng (Qwen-7B-Int4).
3. **Phần mềm:** Ứng dụng Web hoàn chỉnh (Prototype) chạy trên Docker.
4. **Báo cáo khoa học:** Báo cáo tổng kết đề tài chi tiết.

6. KẾT LUẬN

Đề tài đề xuất một hướng tiếp cận hiện đại, giải quyết triệt để bài toán nhập liệu thủ công bằng cách kết hợp sức mạnh của AI tạo sinh và phần cứng máy tính thế hệ mới. Việc tối ưu hóa mô hình ngôn ngữ lớn để chạy trên thiết bị phổ thông (Consumer Hardware) không chỉ chứng minh năng lực công nghệ của sinh viên mà còn mở ra cơ hội ứng dụng rộng rãi, tiết kiệm chi phí cho công cuộc chuyển đổi số quốc gia.